



Der Business Analytics Club für SAS User



GERHARD SVOLBA COMPETENCE CENTER ANALYTICS WIEN, 17. NOVEMBER 2015







PRODUKTBESCHREIBUNG



Was macht das Produkt?

• Es erlaubt große Sammlungen von Text-Dokumenten zu analysieren, Sentiments zu identifizieren und robuste Modelle zur Kategorisierung und Extraktion von Inhalten zu erstellen.

Wie funktioniert das?

- Kombination von automatischer Erkennung, Machine-Learning Methoden, Linguistischer Regeln und Experten-Input zur Entwicklungen eines Kategorisierungs/Extraktions-Modells
- Automatische Identifikation von Themen in den Dokumenten, Definition von Kategorien und Uberarbeitungen durch den Text-Analysten
- Interaktives Testen und visuelle Exploration über ein HTML5-Browser Interface mit Wizards und Context-sensitiver Hilfe.

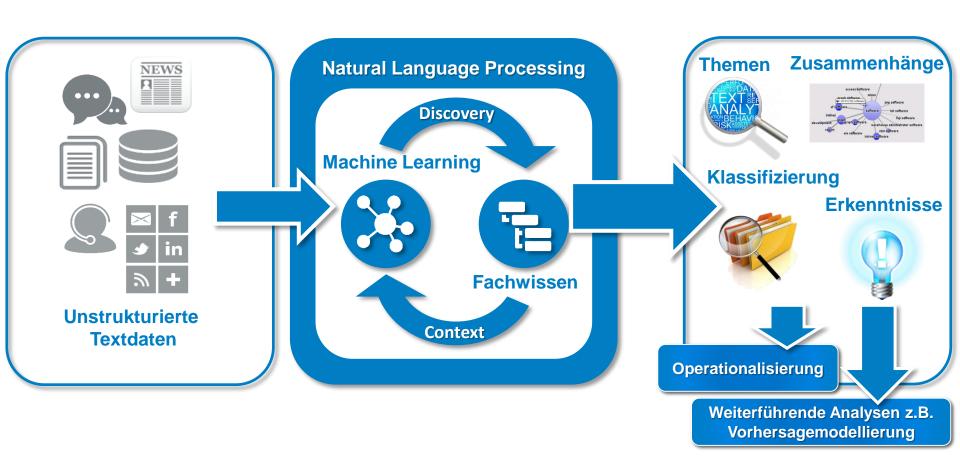
Wie integriert sich SAS Contextual Analysis in das SAS Portfolio?

- Integrierter Teil der SAS Plattform (SAS Metadata Server, ...)
- (Mögliche) Ergänzung zum SAS Text Miner
- Ergebnis-Darstellung mit SAS Visual Analytics, Weiterwendung in SAS Analytik Produkten

SAS® CONTEXTUAL ANALYSIS 14.1

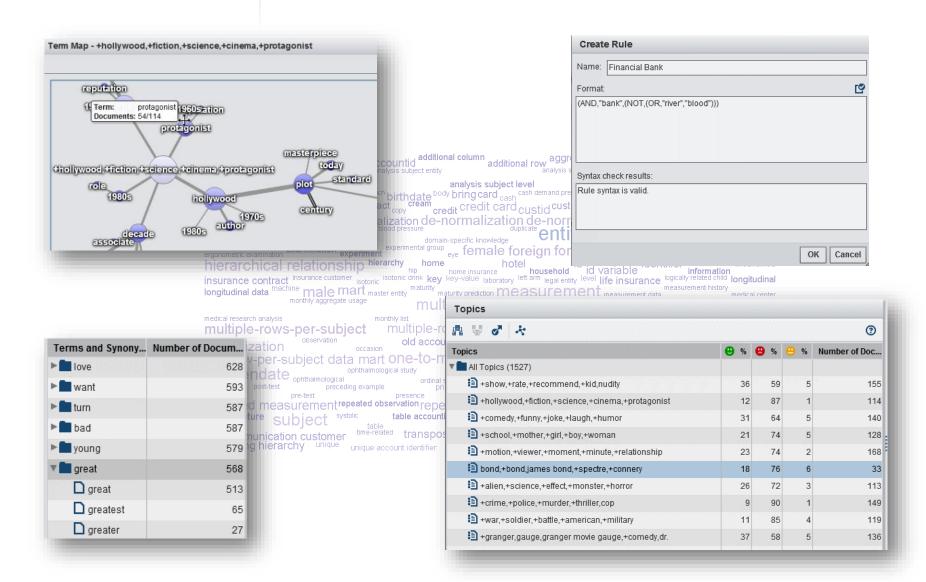
PROZESSFLUSS UND ÖKO-SYSTEM





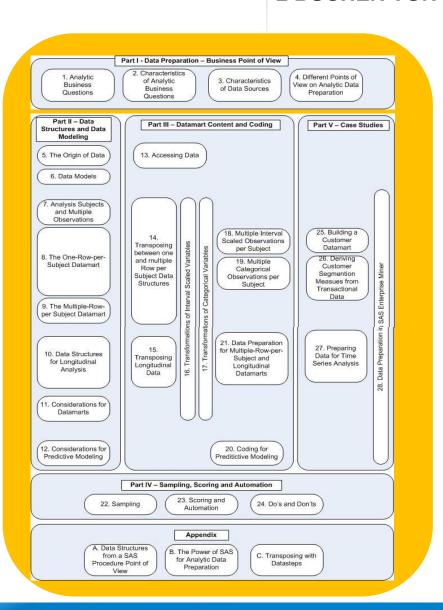
SAS® CONTEXTUAL | BENUTZEROBERFLÄCHE **ANALYSIS 14.1** UND ERGEBNISSE





DER DIE AUSGANGSBASIS: **SELBSTVERSUCH** 2 BÜCHER VON SAS-PRESS





Data Quality Defined

Case Studies – Definition- Availability – Quantity - Completeness - Correctness -Predictive Modeling – Analytics – **Process Considerations**

Profiling and Improvement

Missing Values - Time Series Data -Across Tables – Data Quality with Analytics – **SAS Analytic Tools**

Simulation Studies

Introduction – Predictive Modeling – Time Series Forecasting



ZIELE UND RAHMENBEDINUNGEN



- "Unsupervised" Analyse
- Welche Themen werden gefunden?
- In welche Cluster k\u00f6nnen die Dokumente eingeteilt werden?
- Wodurch beschreiben sich diese Cluster?

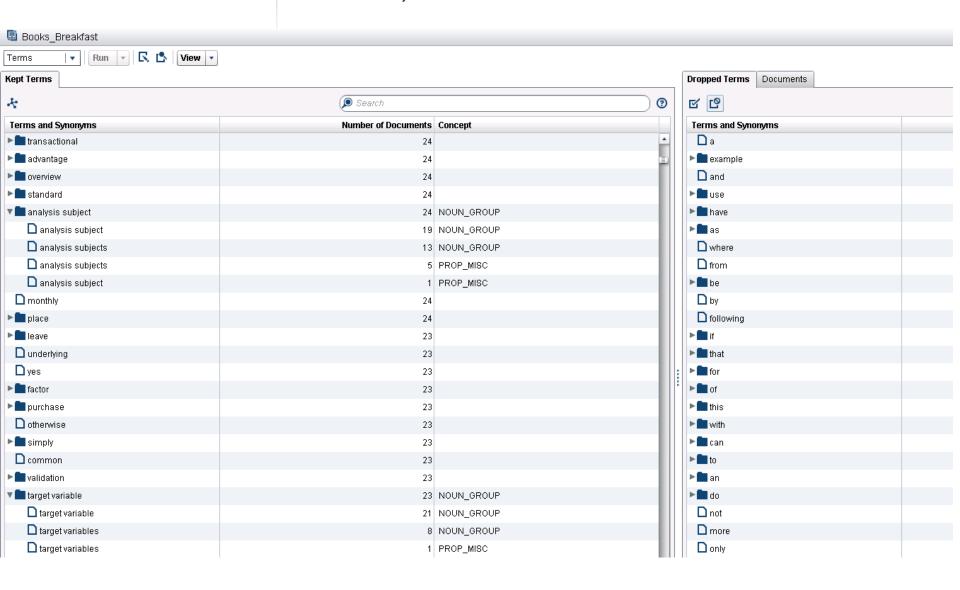
BEREITSTELLUNG DER QUELLDATEN ALS WORD-DOKUMENTE



62 KB 62 KB 136 KB 73 KB 184 KB 284 KB 334 KB 328 KB 503 KB 141 KB 294 KB 104 KB 301 KB 99 KB 287 KB 87 KB 488 KB 105 KB

∃ 🜟 Favorites	Name ^	Date modified	Туре	Size
Desktop	AppA_new.docx	4/17/2012 11:00 AM	Microsoft Word Doc	
Downloads	AppB_new.docx	4/17/2012 11:03 AM	Microsoft Word Doc	
Recent Places	AppC_new.docx	4/17/2012 11:04 AM	Microsoft Word Doc	
] 🔚 Libraries	AppD_new.docx	4/17/2012 11:07 AM	Microsoft Word Doc	
Documents	AppE_new.docx	4/19/2012 3:04 PM	Microsoft Word Doc	
⊕ Music	AppendixA.new.doc	1/8/2007 11:17 AM	Microsoft Word 97	
	AppendixB.new.doc	1/8/2007 11:17 AM	Microsoft Word 97	
∀ Videos	AppendixC.new.doc	1/8/2007 11:17 AM	Microsoft Word 97	
	chap1.new.doc	1/8/2007 11:17 AM	Microsoft Word 97	
🌉 Computer ⊞ 🥌 Local Disk (C:)	el chap1_new.docx	4/13/2012 11:59 AM	Microsoft Word Doc	
☐ ☐ Data (D:)	chap2.new.doc	1/8/2007 11:17 AM	Microsoft Word 97	
⊕ 🍱 data	el chap2_new.docx	4/13/2012 12:01 PM	Microsoft Word Doc	
⊟ 鷆 Gerhard	chap3.new.doc	1/8/2007 11:17 AM	Microsoft Word 97	
\mu Bilder	el chap3_new.docx	4/13/2012 1:11 PM	Microsoft Word Doc	
⊟ 🎉 Data	chap4.new.doc	1/8/2007 11:17 AM	Microsoft Word 97	
□ 🌽 pages	el chap4_new.docx	4/18/2012 9:51 AM	Microsoft Word Doc	
DQFA und DPFA H h FH-Steyr	ehap5.new.doc	1/8/2007 11:17 AM	Microsoft Word 97	
Removed Chapters	el chap5_new.docx	4/13/2012 1:21 PM	Microsoft Word Doc	

AUTOMATISCHE SYNONYM-ERKENNUNG, STOP-LISTEN BERÜCKSICHTIGUNG



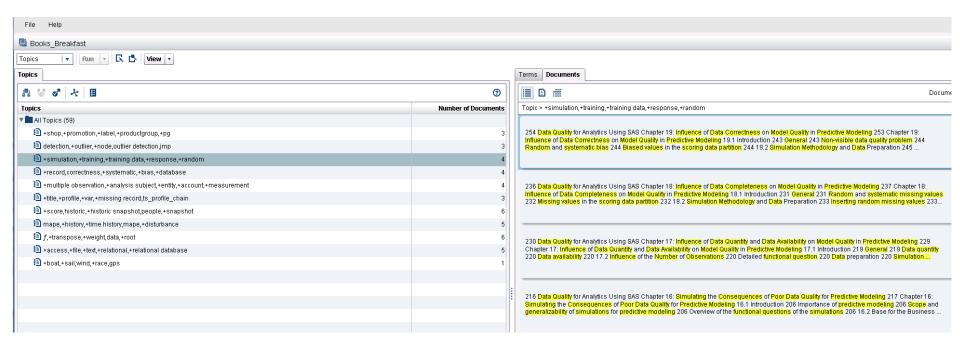
AUS BASIS ANALYTISCHER MODELLE



Topics ▼ Run ▼ K L View ▼	
Topics	
	②
Topics	Number of Documents
▼ ■ All Topics (59)	
+shop,+promotion,+label,+productgroup,+pg	3
detection,+outlier,+node,outlier detection,jmp	3
+simulation,+training,+training data,+response,+random	4
1 +record,correctness,+systematic,+bias,+database	4
+multiple observation,+analysis subject,+entity,+account,+measurement	4
+title,+profile,+var,+missing record,ts_profile_chain	3
🗈 +score,historic,+historic snapshot,people,+snapshot	6
nape,+history,+time history,mape,+disturbance	5
lacksquare f ,+transpose,+weight,data,+root	6
1 +access,+file,+text,+relational,+relational database	5
1 +boat,+sail,wind,+race,gps	1

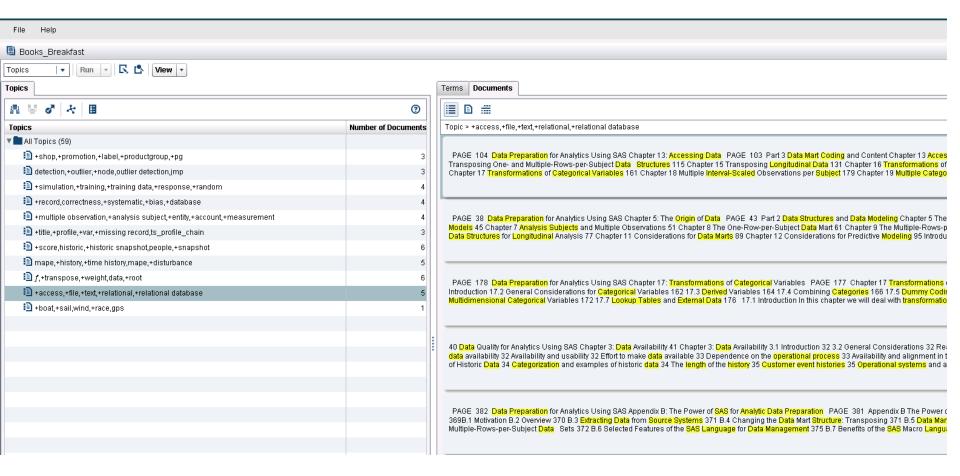
ANZEIGE DER DOKUMENTE PRO THEMA





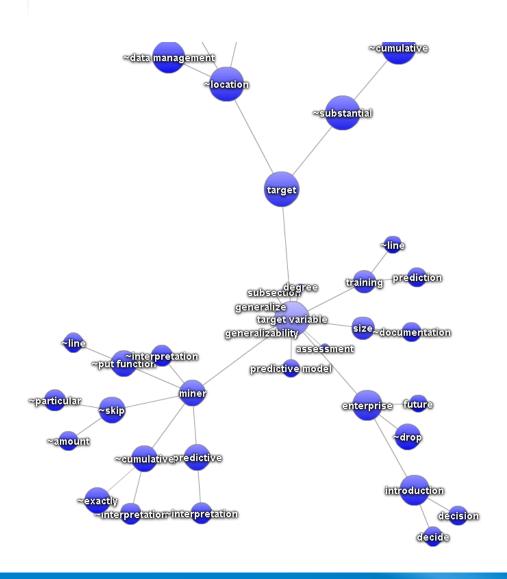
ANZEIGE DER DOKUMENTE PRO THEMA





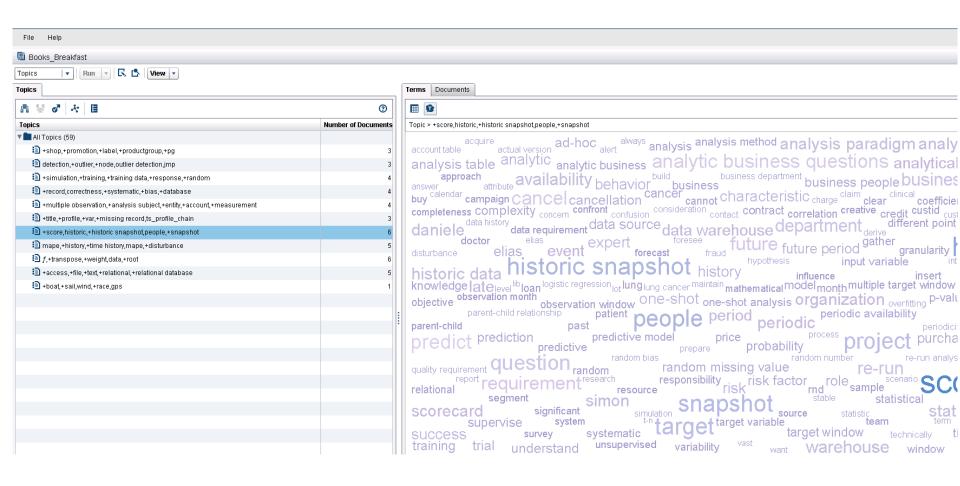
SOFTWARE DEMO | TERM-MAP FÜR EIN THEMA





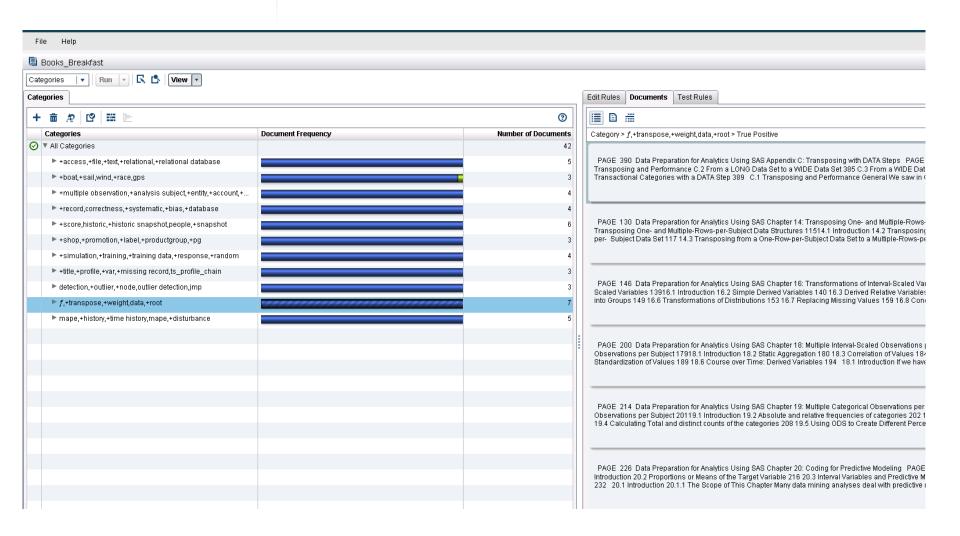
WORD-CLOUD FÜR DIE DOKUMENTE EINES THEMAS





KONVERTIERUNG DER THEMEN IN KATEGORIEN





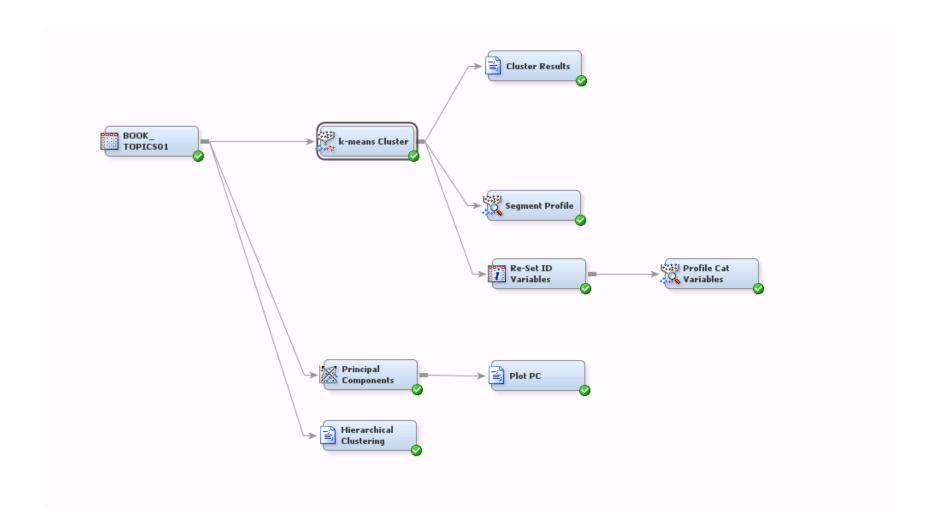
ZUGRIFF AUF DIE TOPIC-WEIGHTS PRO DOKUMENT



	100 topic raw1	10 topic raw2	topic raw3	100 topic raw4	100 topic raw5	100 topic raw6	₁ topic raw7	100 topic raw8	100 topic raw9	10 topic_raw10	10 topic raw11	DOCUMENT A TEXT	A URI	A N
1	0.047	0.007	0.025	0.002	0.018	0.755	.001	0.038	0.092	0.022	0.001	1 298 Data Quali	file://D:\Gerha	. AppA n
2	0.010	0.064	0.023	005	0.014	0.755	0.025	0.015	0.056	0.012	0.014	2 304 Data Quali	file://D:\Gerha	. AppB_n
3	0.011	0.050	0.045	009	0.014	0.049	0.023	0.013	0.030	0.012	0.032	3 306 Data Quali	file://D:\Gerha	. AppC_n
3	0.054	0.026	0.270	053	0.021	0.043	0.023	0.363	0.013	0.015	0.010	4 318 Data Quali	file://D:\Gerha	. AppD_n
4	0.069	0.020	0.014	0.000	0.075	0.037	0.023	0.026	0.040	002	0.002	5 PAGE 368 D	file://D:\Gerha	. Appo_n
0	0.048	0.039	0.024	0.005	0.086	0.069	0.047	0.028	0.031	0.248	0.043	6 PAGE 382 D	. file://D:\Gerha	
7	002	043	0.043	032	0.091	0.086	0.021	0.034	0.143	0.030	0.043	7 PAGE 390 D	. file://D:\Gerha	. Appendi
-	0.031	0.016	0.040	0.061	0.031	0.006	0.003	0.023	0.262	0.056	0.033	8 320 Data Quali	file://D:\Gerha	+
9	0.031	0.016	0.028	0.061	0.736	0.018	0.053	0.013	0.028	0.039	0.032	9 PAGE 2 Dat	file://D:\Gerha	. AppE_n
-														. chap1.n
10	0.165	0.029	0.009	0.022	0.190	0.032	0.058	0.031	0.040	0.058	0.018		. file://D:\Gerha	. chap10.
11	0.022	0.208	0.122	0.061	0.049	0.408	0.050	0.037	0.053	0.043	0.012	11 140 Data Quali	file://D:\Gerha	. chap10_
12	0.041	0.053	0.045	0.023	0.155	0.022	0.076	0.008	0.083	0.082	0.002	12 PAGE 94 Da.	. file://D:\Gerha	. chap11.
13	0.110	0.090	004	0.117	0.039	0.473	0.023	0.097	0.082	0.003	0.009	13 156 Data Quali	file://D:\Gerha	. chap11_
14	0.038	0.023	0.121	0.025	0.055	0.015	0.159	0.021	0.033	0.024	009	14 PAGE 100 D	. file://D:\Gerha	. chap12.
15	0.028	0.035	0.030	0.173	0.134	0.064	028	0.007	0.003	0.077	0.033	15 164 Data Quali	file://D:\Gerha	. chap12_
16	0.058	0.024	0.026	0.020	0.103	0.029	0.008	0.015	0.061	0.492	0.016	16 PAGE 104 D	. file://D:\Gerha	. chap13.
17	0.007	0.377	0.092	0.110	0.075	0.064	0.082	0.072	0.069	0.034	0.048	17 178 Data Quali	file://D:\Gerha	. chap13_
18	0.007	0.004	0.020	014	0.150	0.071	0.013	0.028	0.342	0.036	0.091	18 PAGE 130 D	. file://D:\Gerha	. chap14.
19	0.033	0.483	0.124	0.061	0.049	0.115	0.074	0.072	0.035	0.072	0.150	19 198 Data Quali	file://D:\Gerha	. chap14_
20	0.066	0.012	0.006	015	0.064	0.054	0.004	0.030	0.070	0.030	0.013	20 PAGE 138 D	. file://D:\Gerha	. chap15.
21	0.011	0.038	0.223	0.089	0.020	0.037	0.014	0.120	0.025	0.021	0.045	21 Part III: Conseq	. file://D:\Gerha	. chap15_
22	0.076	0.042	0.069	0.127	0.044	0.106	0.053	0.023	0.482	0.043	0.030	22 PAGE 146 D	. file://D:\Gerha	. chap16.
23	0.024	0.091	0.430	0.053	0.048	0.039	0.104	0.125	0.001	0.027	0.032	23 216 Data Quali	file://D:\Gerha	. chap16_
24	0.077	0.136	0.031	0.010	0.070	0.035	0.036	0.016	0.107	0.284	027	24 PAGE 178 D	. file://D:\Gerha	. chap17.
25	0.027	0.041	0.458	0.037	0.025	0.022	0.049	0.068	0.026	0.009	0.020	25 230 Data Quali	file://D:\Gerha	. chap17_
26	0.108	0.063	0.027	0.013	0.118	0.055	0.058	0.056	0.304	0.042	0.006	26 PAGE 200 D	. file://D:\Gerha	. chap18.
27	0.012	0.043	0.500	0.114	0.028	0.051	0.042	0.094	0.033	0.011	004	27 236 Data Quali	file://D:\Gerha	. chap18_
28	0.043	0.039	0.053	009	0.086	0.017	0.018	004	0.265	0.087	017	28 PAGE 214 D	. file://D:\Gerha	. chap19.
29	0.005	0.010	0.538	0.152	0.028	0.031	0.021	0.144	0.062	0.005	0.009	29 254 Data Quali	file://D:\Gerha	. chap19_
30	0.062	0.118	0.069	0.176	0.075	0.037	0.103	0.074	0.027	0.090	0.889	30 Part I: Data Qu	file://D:\Gerha	. chap1_r
31	0.024	0.053	0.071	0.040	0.134	0.031	0.368	0.033	0.035	0.036	0.004	31 PAGE 20 Da	. file://D:\Gerha	. chap2.n
32	0.047	0.026	0.180	007	0.019	0.086	0.069	020	0.234	0.068	009	32 PAGE 226 D	. file://D:\Gerha	. chap20.
33	0.060	0.064	0.188	0.037	0.036	0.052	0.069	0.445	0.017	0.028	0.044	33 262 Data Quali	file://D:\Gerha	. chap20_
34	0.414	0.040	001	0.052	0.089	0.074	0.037	0.052	0.191	0.046	0.020	34 PAGE 254 D	. file://D:\Gerha	. chap21.
35	0.023	0.048	0.081	006	0.035	0.017	0.064	0.450	0.006	0.022	0.029	35 272 Data Quali	file://D:\Gerha	. chap21_
36	0.043	0.023	0.128	030	0.070	0.094	0.040	0.013	0.109	0.030	0.016	36 PAGE 256 D	. file://D:\Gerha	. chap22.
37	0.033	0.049	0.210	0.090	0.021	0.080	029	0.388	0.050	0.005	001	37 274 Data Quali	file://D:\Gerha	. chap22_
38	0.061	0.070	0.129	125	0.045	0.204	0.144	0.021	0.122	0.062	0.032	38 PAGE 292 D	. file://D:\Gerha	. chap23.
39	0.019	0.014	0.163	0.061	0.017	0.042	0.012	0.469	0.034	0.008	0.003	39 288 Data Quali	file://D:\Gerha	. chap23_

CLUSTERING DER DOKUMENTE IM SAS ENTERPRISE MINER





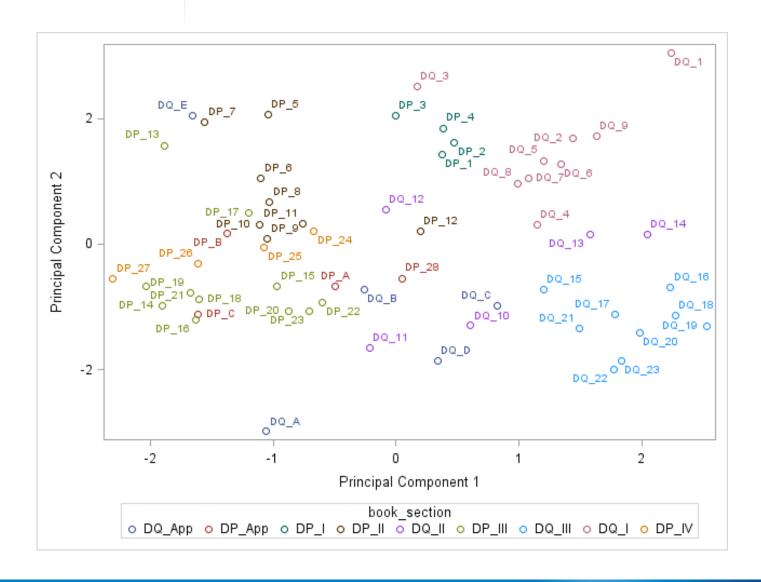
CLUSTER-ERGEBNISSE AUF BASIS DER TEXT-TOPIC ANALYSE



1	Missing Values	10	11	А																	
2	Erzeugen des Analytic-Marts	10	11	14	15	16	18	19	20	21	22	23	24	25	26	27	28	9	А	С	В
3	Data Origin und Data Management	5	13	17	В																
4	DQ Case Studies	1																			
5	Fachliche Konzepte	1	2	3	4	12	2	3	4	5	6	7	8	9	12						
6	DQ mit Analytik und SAS	13	14																		
7	Data Quality Simulationen	15	16	17	18	19	20	21	22	23	С	D									
8	Analytic Data Mart Structures	6	7	8	Е																

SCATTER-PLOT DER KAPITEL BZGL. DIE 1. UND 2. HAUPTKOMPONENTE





KUNDEN-FEEDBACK AUF EINEM WEB-PORTAL



Sammlung von 17.205 Kunden-Feedback Nachrichten auf einem Web-Portal



- Wie denken die Kunden über uns?
- Automatisches Routing zur relevanten Stelle?
- Monitoring über die Zeit





ANWENDUNGS-BEISPIEL 1

KUNDEN-FEEDBACK AUF EINEM WEB-PORTAL (FORTS.)



Direkter Zugriff auf diese Nachrichten (Web Crawler, Datenintegration)

Automatische Erkennung von 23 "Themen" (Topics) in diesem Nachrichten-Pool mit Hilfe von Text Mining und Natural Language Processing

Manuelle Verfeinerung/Zusammenfassung zu 21 Themen

Automatisches Ableiten der entsprechenden Kategorie pro Topic auf Basis linguistischer Regeln

Testen der Treffsicherheit dieser 21 Kategorien

Regelmäßiges, automatisches Anwenden dieser linguistischen Regeln zur Zuweisung (Routing) von Kunden-Feedbacks zu den Kategorien

Datenintegration

Analytik

Manuelle Interaktion

Analytik

Validierung, Tuning

Operatives Scoring



ANWENDUNGS- | VERTRAGS-TEXTE UND KLAUSELN IN EINER TEXT-DATENBANK



62.837 Vertragstexte in PDF-Form auf einem File-Server

- In welche Gruppen können die Vertragstexte gruppiert werden?
- Wie deckt sich diese Gruppierung mit anderen Vertragskategorien?
- Können bestimmte Klauseln vereinheitlicht werden?









ANWENDUNGS-BEISPIEL 2

VERTRAGS-TEXTE UND KLAUSELN IN EINER TEXT-DATENBANK (FORTS.)



Einlesen der Daten direkt aus den PDF-Dokumenter

Automatische Erkennung von 61 Themen in den Vertragstexten.

Definition einer hierarchischen Themenstruktur mit 14 Haupt-Themen, 61 Themen und 137 Sub-Themen

Ableiten von Kategorien aus diesen Themen

Profiling der Eigenschaften der einzelnen Kategorien und Themen

Identifikation der häufigsten Inhalte der Vertragstexte und der Verteilung über die Dokumente

Datenintegration

Analytik

Manuelle Interaktion

Analytik

Validierung, Tuning

Erkenntnisgewinn

EINBETTUNG IN DIE SAS PLATTFORM



SAS TEXT ANALYTICS

CONTEXTUAL **ANALYSIS**

- Information Retrieval
- **Automatische Themen** Erkennung
- **Content Kategorisierung**
- Extraktion von Entitäten
- **Sentiment Analyse**



TEXT MINING

Erkennen von wertvollen Mustern, Themen und Einblicken aus Text-Daten

INTEGRIERTE **ANALYTIK**

Integration strukturierte und unstrukturierten Daten

- **Predictive Modeling**
- **Netzwerk Analyse**



WEITERE INFORMATIONEN



- Gerne im direkten Gespräch mit uns persönlich.
- SAS-Webinar zu SAS Contextual Analysis Demo
- Text Analytics auf der Deutschen SAS-Website
- Fact Sheet
- Beitrag im Mehr-Wissen Blog vom 30. Oktober 2015

